

Tema 1

SISTEMAS DE ALMACENAMIENTO DE LA INFORMACIÓN

IES Francisco Romero Vargas
Departamento de Informática

1. Gestión de datos

En el mundo actual existe una demanda cada vez mayor de datos y, por tanto, más necesidad de gestionarlos. Esta demanda siempre ha sido patente en empresas y sociedades, pero en estos años la demanda todavía se ha disparado más debido al acceso multitudinario a las redes integradas en Internet y a la utilización de pequeños dispositivos (móviles y PDA) que también requieren esa información.

En informática se conoce como **dato** a cualquier elemento informativo que tenga relevancia para un usuario. Desde su nacimiento, la informática se ha encargado de proporcionar herramientas que faciliten la manipulación de los datos.

Los sistemas de información actuales se basan en **bases de datos y sistemas de bases de datos**, que se han convertido en elementos imprescindibles de la vida cotidiana de la sociedad moderna.

Cada día, la mayoría de nosotros nos encontramos con actividades que requieren algún tipo de interacción con una base de datos (ingreso en un banco, reserva de una entrada para el teatro, solicitud de una suscripción a una revista, compra de productos, ...). Estas interacciones son ejemplos de lo que se llama **aplicaciones tradicionales de bases de datos**.

Una base de datos será, por tanto, una colección de datos relacionados. Por datos queremos decir hechos conocidos que pueden registrarse y que tienen un significado implícito. Una agenda con los nombres, las fotografías y los teléfonos de un conjunto de personas conocidas es una base de datos, puesto que es una colección de datos relacionados con un significado implícito.

Actualmente, debido a la gran cantidad de información con la que se cuenta, aparece el concepto de **Big Data**. Denominamos así a la gestión y análisis de enormes volúmenes de datos que no pueden ser tratados de manera convencional, ya que superan los límites y capacidades de las herramientas de software habitualmente utilizadas para la captura, gestión y procesamiento de datos.

Dicho concepto engloba infraestructuras, tecnologías y servicios que han sido creados para dar solución al procesamiento de enormes conjuntos de datos estructurados, no estructurados o semi-estructurados (mensajes en redes

sociales, señales de móvil, archivos de audio, sensores, imágenes digitales, datos de formularios, emails, datos de encuestas, logs etc,) que pueden provenir de sensores, micrófonos, cámaras, escáneres médicos, imágenes, ...

El objetivo de Big Data, al igual que los sistemas analíticos convencionales, es convertir el Dato en información que facilita la toma de decisiones, incluso en tiempo real. Sin embargo, más que una cuestión de tamaño, es una oportunidad de negocio. Las empresas ya están utilizando Big Data para entender el perfil, las necesidades y el sentir de sus clientes respecto a los productos y/o servicios vendidos. Esto adquiere especial relevancia ya que permite adecuar la forma en la que interactúa la empresa con sus clientes y en cómo les prestan servicio.

2. Sistemas de información

Los sistemas que aglutinan los elementos que intervienen para gestionar la información que manejan cualquier entidad, empresa o institución es lo que se conoce como **Sistemas de Información**.

Un sistema de información es un sistema que almacena y gestiona la información relevante de una empresa/institución/entidad.

Un sistema de información genérico está formado por los siguientes elementos:

- **Recursos físicos.** Carpetas, documentos, equipamiento, discos,...
- **Recursos humanos.** Personal que maneja la información.
- **Reglas.** Normas que debe cumplir la información para que sea manejada (formato de la información, modelo para los documentos, interfaces de usuario, roles, ...), es decir, las normas, métodos y protocolos determinados por la planificación de la empresa.

Cuando parte o toda la gestión de un sistema de información se realiza con ordenadores se habla de sistema de información basado en ordenadores o **sistema informático**. En este caso a las reglas de la empresa se añaden las normas determinadas por el sistema operativo de los ordenadores y demás software instalado en ellos.

Componentes de un sistema informático

- **Datos.** Se trata de la información relevante que almacena y gestiona el sistema de información. Esta información suele estar almacenada en bases de datos que cumplen con los requerimientos o normas de la empresa.
- **Hardware.** Equipamiento físico que se utiliza para gestionar los datos.
- **Software.** Aplicaciones que permiten el funcionamiento adecuado del sistema.
- **Recursos humanos.** Personal que maneja el sistema de información.

Tipos de sistemas informáticos

Según el propósito, los sistemas de información se pueden clasificar en:

- **Transaccionales.** Se ocupan de la automatización de las operaciones y transacciones que se realizan en la empresa, por ejemplo, las actividades que realizan los empleados de manera cotidiana (fichar a la hora de entrada del trabajo, firmar, ...)
- **De Gestión.** Se ocupan de los datos que se manejan en la empresa y su almacenamiento. Por ejemplo controlan cómo se almacenan los datos en las bases de datos, cómo se recupera esa información, cómo se obtienen listados, informes, etc.
- **De soporte a la decisión.** Su misión es ayudar a los directivos y personal con responsabilidad dentro de la empresa en la toma de decisiones estratégicas. Estos sistemas están emparentados con las técnicas de inteligencia artificial y los sistemas expertos y son cada vez más comunes e importantes dentro de las empresas.
- **Ofimática, sistemas expertos y sistemas inteligentes** son otros tipos de sistemas de información informáticos.


Tipos de sistemas de información de gestión de datos

Los sistemas de información pueden diferenciarse en orientados al proceso (sistema clásico de ficheros) u orientados a los datos (sistema de bases de datos).

El uso de uno u otro sistema depende de la fecha en la que el sistema informático fue implantado en la empresa. En los años 60/70 se usaban ficheros de datos a los que se accedía a través de lenguajes de programación como Cobol, C, Basic, ... (algunos bancos actuales siguen usando ese sistema). A mediados de los 70 se crean los primeros gestores de bases de datos que evolucionan hasta los conocidos relacionales SQL Server, ORACLE, MySQL, MariaDB Informix, ... En la actualidad, la gran cantidad de datos a procesar requiere de bases de datos avanzadas que aportan una mezcla entre la idea de orientación a proceso y orientación a datos: las denominadas NoSQL como MongoDB o Redis.

- Sistemas de información orientados al proceso:
FICHEROS

En estos sistemas de información se crean diversas aplicaciones (software) para gestionar diferentes aspectos del sistema. Cada aplicación realiza unas determinadas operaciones.



Los datos de dichas aplicaciones se almacenan en archivos digitales dentro de las unidades de almacenamiento del ordenador (a veces en archivos binarios, o en hojas de cálculo, ...).

En estos sistemas, cada programa almacena y utiliza sus propios datos de forma un tanto caótica. La única ventaja que conlleva esto es que los procesos son independientes, por lo que la modificación de uno no afecta al resto. Pero tiene grandes inconvenientes:

- **Coste de almacenamiento elevado.** Al almacenarse varias veces el mismo dato en distintas aplicaciones, se requiere más espacio en los discos.
 - **Datos redundantes.** Ya que se repiten continuamente.
 - **Probabilidad alta de inconsistencia en los datos.** Ya que un proceso cambia sus datos y no el resto. Por lo que el mismo dato puede tener valores distintos según qué aplicación acceda a él.
 - **Difícil modificación en los datos** Debido a la probabilidad de inconsistencia, que ocurre cuando se produce una pérdida o hay incoherencia de datos. Para que ésta no exista, cada modificación se debe repetir en todas las copias del dato (algo que normalmente es imposible).
 - **Tiempos de procesamiento elevados.** Al no poder optimizar el espacio de almacenamiento.
- Sistemas de información orientados a los datos: BASES DE DATOS

En este tipo de sistemas los datos se centralizan en una **base de datos** común a todas las aplicaciones.

Un software llamado **Sistema Gestor de Bases de Datos (SGBD)** es el que realmente accede a los datos y se encarga de gestionarlos. Las aplicaciones que creen los programadores, no acceden directamente a los datos, de modo que la base de datos es común para todas las aplicaciones.

Cuando una aplicación modifica un dato, la modificación será visible inmediatamente para el resto de aplicaciones; ya que todas utilizarán la misma base de datos.



VENTAJAS	INCONVENIENTES
Independencia de los datos y los programas y procesos. Esto permite modificar los datos sin modificar el código de las aplicaciones. Menor redundancia. No hace falta tanta repetición de datos. Aunque, sólo los buenos diseños de datos tienen poca redundancia. Integridad de los datos. Mayor dificultad de perder los datos o de realizar incoherencias con ellos. Mayor seguridad en los datos. Al limitar el acceso a ciertos usuarios. Datos más documentados. Gracias a los metadatos que permiten describir la información de la base de datos. Acceso a los datos más eficiente. La organización de los datos produce un resultado más óptimo en rendimiento. Menor espacio de almacenamiento. Gracias a una mejor estructuración de los datos.	Instalación costosa. El control y administración de bases de datos requiere de un software y hardware poderoso Requiere personal cualificado. Debido a la "dificultad" de manejo de este tipo de sistemas. Implantación larga y difícil. Debido a los puntos anteriores. La adaptación del personal es mucho más complicada y lleva bastante tiempo. Ausencia de estándares reales. Lo cual significa una excesiva dependencia hacia los sistemas comerciales del mercado. Aunque hay una buena parte de esta tecnología aceptada como estándar de hecho.

3. Sistemas de ficheros

Un *sistema de ficheros* es un conjunto de programas que prestan servicio a los usuarios finales. Cada programa define y maneja sus propios datos.

Los archivos, como herramienta para almacenar información, tomaron la terminología del mundo de la oficina empresarial. Así la palabra **dato** hace referencia a un valor sea un número o un texto o cualquier otro tipo de datos almacenable.

Cuando podemos distinguir datos referidos a una misma propiedad real a la que podemos poner un nombre, hablamos de **campos**. Así: *Sánchez, Rodríguez, Serrat y Crespo* son datos que perfectamente podrían encajar en un campo llamado *Primer Apellido*.

Los datos que se refieren al mismo elemento real (una persona, una factura, un movimiento bancario,...) se agrupan en **registros**. En un fichero de datos personales, cada registro sería una persona; cada campo sería cada propiedad distinguible en la persona.

Tipos de ficheros según su estructura física

Ficheros secuenciales

En estos ficheros, los datos se organizan secuencialmente en el orden en el que fueron grabados. Para leer los últimos datos hay que leer los anteriores. Es decir leer el registro número nueve, implica leer previamente los ocho anteriores.

ventajas

- Rápidos para obtener registros contiguos de una base de datos
- No hay huecos en el archivo al grabarse los datos seguidos, datos más compactos.

desventajas


- Consultas muy lentas al tener que leer todos los registros anteriores en el orden del archivo respecto al que queremos leer. Es decir, que si queremos leer el quinto registro, hay que leer los cuatro anteriores.
- Algoritmos de lectura y escritura complejos. No es fácil hacer operaciones avanzadas con los datos.
- No se pueden eliminar registros del fichero (se pueden marcar de manera especial para que no sean tenidos en cuenta, pero no se pueden borrar).
- El borrado provoca archivos que no son compactos.

- La ordenación de los datos requiere leer todos los datos, reorganizarlos en memoria y volver a grabarles en el archivo en el orden correcto. Se trata de una operación excesivamente lenta.

Ficheros de acceso directo o aleatorio

En estos ficheros se puede leer una posición concreta directamente; bastará saber la posición exacta (normalmente en bytes) del dato a leer para obtenerle. Es decir, posicionarnos en el quinto registro se haría de golpe, con una sola instrucción. Lo único que necesitamos saber es el tamaño de cada registro, que en este tipo de ficheros debe de ser el mismo. Suponiendo que cada registro ocupa 100 bytes, el quinto registro comenzará en la posición 400. A partir de esa posición podremos leer todos los datos del registro.

fichero acceso directo



ventajas

- Acceso rápido a un registro concreto. No necesita leer los datos anteriores
- La modificación de datos es más sencilla
- Permiten acceso secuencial además del aleatorio (por lo que mejoran el caso anterior)
- Permiten tanto leer como escribir a sin necesidad de cerrar el archivo.

- Aptos para organizaciones **relativas directas**, en las que la clave del registro se relaciona con su posición en el archivo.

desventajas

- Salvo en archivos relativos directos, no es apto por sí mismo para usar en bases de datos, ya que los datos se organizan en base a una clave que casi nunca coincide con la posición del registro en el archivo
- No se pueden borrar datos (sí marcar para borrado, pero generarán huecos)
- Las consultas sobre multitud de registros son más lentas que en el caso anterior.

Ficheros secuenciales encadenados

Son ficheros con registros grabados secuencialmente que podríamos recorrer registro a registro o de forma aleatoria. Además cada registro posee un campo que contiene la dirección de otro registro (a este tipo de campos se les llama **punteros**). Cada registro usa su puntero para indicar la dirección del siguiente registro. Usando los punteros podremos recorrer los registros en un orden concreto. Cuando aparece un nuevo registro, se añade al final del archivo, pero los punteros se reordenan para que se mantenga el orden.

fichero secuencial encadenado



ventajas

- El fichero mantiene el orden en el que se añadieron los registros y un segundo orden en base a una clave. Incluso añadiendo más punteros a cada registro podremos establecer más formas de ordenar los registros.
- La operación de ordenación no requiere reorganizar todo el fichero, sino sólo modificar los punteros
- Posee las mismas ventajas que el acceso secuencial y el acceso aleatorio

desventajas

- No se borran los registros, sino que se marcan para ser ignorados. Por lo que se malgasta espacio
- Añadir registros o modificar las claves son operaciones que requieren recalcular los punteros por lo que llevan más tiempo que en los casos anteriores

Ficheros secuenciales indexados


Se utilizan dos ficheros para los datos, uno posee los registros almacenados de forma secuencial, pero que permite su acceso aleatorio. El otro posee una tabla con punteros a la posición ordenada de los registros. Ese segundo fichero es el **índice**, una tabla con la ordenación deseada para los registros y la posición que ocupan en el archivo.

El archivo de índices posee unas cuantas entradas sólo en las que se indica la posición de ciertos valores claves en el archivo (cada 10, 15 ,20,... registros del archivo principal se añade una entrada en el de índices). El archivo principal tiene que estar siempre ordenado y así cuando se busca un registro, se busca su valor clave en la tabla de índices, la cual poseerá la posición del registro buscado. Desde esa posición se busca secuencialmente el registro hasta encontrarlo.

Existe un tercer archivo llamado de **desbordamiento** u **overflow** en el que se colocan los nuevos registros que se van añadiendo (para no tener que ordenar el archivo principal cada vez que se añade un nuevo registro) este archivo está desordenado. Se utiliza sólo si se busca un registro y no se encuentra en el archivo principal. En ese caso se recorre todo el archivo de overflow hasta encontrarlo.

Para no tener demasiados archivos en overflow (lo que restaría velocidad ya que no utilizaríamos el archivo de índices que es el que da velocidad), cada cierto tiempo se reorganiza el archivo principal, ordenando los datos en el orden correcto y recalculando el archivo de índices. Ejemplo:

fichero secuencial indexado



ventajas

- El archivo está siempre ordenado de forma secuencial en base a una clave. Por lo que la simple lectura secuencial del archivo obtiene un listado ordenado de los datos.
- La búsqueda de datos es rapidísima
- Permite la lectura secuencial (que además será en el orden de la clave)
- Añadir un solo registro no conlleva un tiempo extra como en el caso anterior

desventajas

- Para un uso óptimo hay que reorganizar el archivo principal cada cierto tiempo y esta operación es muy costosa ya que hay que reescribir de nuevo y de forma ordenada todo el archivo con el área primaria, además de reorganizar el área de índices y eliminar el fichero de desbordamiento. Es tan costosa que se hace muy poco a menudo, pero en archivos de datos que se modifican muy a menudo, no reorganizar

provocaría un área de desbordamiento enorme y perderíamos las ventajas de este modelo.

Ficheros indexado-encadenados

Utiliza punteros e índices, es una variante encadenada del caso anterior. Hay un fichero de índices equivalente al comentado en el caso anterior y otro fichero de tipo encadenado con punteros a los siguientes registros. La diferencia está en que este segundo fichero que contiene el área primaria de los datos, no está ordenado secuencialmente, sino que el orden se realizaría recorriendo un puntero (como en el caso de los ficheros secuencialmente encadenados).

Cuando se añaden registros se añaden en un tercer fichero llamado de desbordamiento u **overflow**. En el área de desbordamiento los datos se almacenan secuencialmente, se accede a ellos si se busca un dato y no se encuentra el área primaria.



ventajas

- Posee las mismas ventajas que el modelo anterior además de que la reordenación es más rápida ya que sólo requiere modificar los punteros y el área de índices (no requiere reordenar todos los datos del área primaria).

desventajas

- Requieren compactar los datos a menudo para reorganizar índices y quitar el fichero de desbordamiento y es una operación lenta (aunque mucho menos lenta que en el caso anterior)

Tipos de ficheros según su uso

- **Maestros.** Ficheros que se cambian muy poco a menudo. Son los principales en los sistemas de información. Contienen los datos fundamentales.
- **Constantes.** Contienen información que apenas varía a lo largo del tiempo.
- **Históricos.** Contienen los datos de los ficheros maestros pasado un determinado tiempo.
- **De movimiento.** Almacenan cambios a realizar en los ficheros maestros. Se eliminan tras realizar esos cambios.
- **De maniobra.** Ficheros auxiliares utilizados por el software que gestiona los datos. Son destruidos en cuanto las aplicaciones finalizan.

4. Sistemas de Bases de Datos

Un **Sistema de Bases de Datos** es un sistema basado en ordenadores, cuyo propósito general es registrar y mantener datos mediante un sistema gestor de BD. Permite a los usuarios y aplicaciones la consulta y manipulación de estos datos - almacenados en bases de datos - usando un lenguaje de consulta estructurado: SQL (Structured Query Language).

Como se ha comentado anteriormente, cuando los datos de un sistema de información se almacenan en una única estructura, se llama base de datos. Se presentan a continuación dos definiciones:

Una **base de datos** es una **colección de datos almacenados en un soporte informático permanente de forma que sea posible obtener la relación entre los datos a través de un esquema conceptual que oculte la física real de los datos**.

Una base de datos es una **colección de datos estructurados según un modelo que refleje las relaciones y restricciones existentes en el**

mundo real. Los datos, que han de ser compartidos por diferentes usuarios y aplicaciones, deben mantenerse independientes de ésta, y su definición y descripción han de ser únicas estando almacenados junto a los mismos. Por último, los tratamientos que sufran estos datos tendrán que conservar la integridad y seguridad de éstos.

El objetivo es que las aplicaciones puedan acceder a los datos sin necesidad de conocer exactamente cómo están almacenados los datos. Esto se consigue con un esquema conocido como **esquema conceptual**. Cualquier desarrollador que conozca ese esquema puede acceder a los datos desde cualquier aplicación.

Componentes de un sistema de base de datos

Los elementos de un sistema de base de datos son los mismos que los de un sistema de información. Se comentan a continuación para concretar un poco más la información que ya poseíamos:

- **Hardware.** Máquinas en las que se almacenan las bases de datos. Se compone de los volúmenes de almacenamiento secundario (discos, cintas, ...) donde reside la BD, junto con los dispositivos asociados como unidad de control, tarjetas, memoria, ...
- **Software.** Es el sistema gestor de bases de datos, es decir, la aplicación que permite el manejo de la base de datos. Entre la BD física y los usuarios del sistema, existe un nivel de software que recibe el nombre de **SGBD**. Este maneja todas las solicitudes de acceso a la BD y registra y mantiene de forma controlada los datos almacenados. Asimismo pueden existir uno o varios programas para permitir el acceso a las BD realizando consultas. Estas **aplicaciones** accederán a las BD usando el lenguaje de consultas SQL mediante los servicios ofrecidos por el SGBD.
- **Datos.** Incluyen los datos que se necesitan almacenar y los **metadatos** que son datos que sirven para describir lo que se almacena en la base de datos. Los datos almacenados en el sistema se dividen en una o más bases de datos. Una BD es **integrada**, ya que puede considerarse como una unificación de varios archivos de datos independientes, donde se eliminan cualquier redundancia entre los mismos. Una BD es **compartida**, en el sentido en que partes individuales de la BD pueden compartirse entre varios usuarios distintos, de tal forma que cada uno

de ellos puede tener acceso a la misma parte de la BD. Hay que considerar que aunque dos usuarios compartan el mismo subconjunto de la BD, sus percepciones o vistas de ese conjunto pueden diferir mucho a nivel de detalle. La palabra "compartida" a menudo se amplía para abarcar no sólo al comportamiento antes descrito, sino también al acceso *concurrente*, es decir, la posibilidad de que varios usuarios accedan a la misma BD (tal vez incluso a la misma parte) al mismo tiempo. Un SBD que admite esta forma de acceso se llama **Sistema de Usuarios Múltiples**.

- **Usuarios.** Personas que manipulan los datos del sistema. Hay cuatro grupos de personas que intervienen en el entorno de una base de datos: el administrador de la base de datos, los diseñadores de la base de datos, los programadores de aplicaciones y los usuarios.
 - El **administrador de la base de datos** (ABD o DBA) se encarga del diseño físico de la base de datos y de su implementación, realiza el control de la seguridad y de la concurrencia, mantiene el sistema para que siempre se encuentre operativo y se encarga de que los usuarios y las aplicaciones obtengan buenas prestaciones. El administrador debe conocer muy bien el SGBD que se esté utilizando, así como el equipo informático sobre el que esté funcionando. El DBA, en resumen, autoriza el acceso a la BD, coordina y vigila su utilización, adquiere los recursos de software y hardware necesarios y es el responsable ante los problemas de violaciones de seguridad o respuesta lenta del sistema.
 - Los **analistas o diseñadores de la base de datos** realizan el diseño lógico de la base de datos, debiendo identificar los datos, las relaciones entre datos y las restricciones sobre los datos y sus relaciones. El diseñador de la base de datos debe tener un profundo conocimiento de los datos de la empresa y también debe conocer sus *reglas de negocio*. Las reglas de negocio describen las características principales de los datos tal y como las ve la empresa. Para obtener un buen resultado, el diseñador de la base de datos debe implicar en el desarrollo del modelo de datos a todos los usuarios de la base de datos, tan pronto como sea posible. El diseño lógico de la base de datos es independiente del SGBD concreto que se vaya a utilizar, es independiente de los programas de aplicación, de los lenguajes de programación y de cualquier otra consideración física. El diseñador, en resumen, identifica los datos que se van a almacenar en la BD, elige las

estructuras apropiadas, se comunica con los futuros usuarios de la BD con el fin de comprender sus necesidades y requerimientos.

- Una vez se ha diseñado e implementado la base de datos, los **programadores de aplicaciones** se encargan de implementar los programas de aplicación que servirán a los usuarios finales. Estos programas de aplicación son los que permiten consultar datos, insertarlos, actualizarlos y eliminarlos. Estos programas se escriben mediante lenguajes de tercera generación o de cuarta generación. El programador, en resumen, implementa las especificaciones realizadas por los analistas/diseñadores en forma de programas y luego prueba, depura, documenta y mantiene estas transacciones programadas, debiendo conocer a la perfección toda la gama de capacidades del SGBD.
- Los **usuarios finales** son los clientes de la base de datos: la base de datos ha sido diseñada e implementada, y está siendo mantenida, para satisfacer sus requisitos en la gestión de su información.


Hay que tener en cuenta que las necesidades de los usuarios son muy diferentes en función del tipo de usuario que sean: a los finales les interesa la facilidad de uso, a los desarrolladores la potencia y flexibilidad de los lenguajes incorporados del sistema de bases de datos y a los administradores herramientas de gestión avanzada para la base de datos.

4.1. Proceso de creación y manipulación de una BD

Fase de creación:

1. El **analista** o **diseñador** crea el esquema conceptual. En muchas ocasiones, utilizando una **herramienta CASE** (Computer Aided Software Engineering, Ingeniería de Software Asistida por Computadora) para diseñar el esquema de forma más cómoda.
2. El **administrador** de la base de datos (**DBA**) recoge ese esquema y crea el esquema interno de la base de datos. También se encarga, previamente, de determinar el SGBD idóneo y de configurar el software del SGBD así como de establecer las políticas de copia de seguridad.

3. Los **desarrolladores** también recogen el esquema conceptual y utilizan las aplicaciones necesarias para generar los esquemas externos, que realmente se traducirán en programas y aplicaciones, que necesitan los usuarios.



Fase de manipulación:


Ocurre con la base de datos ya creada y en funcionamiento.

1. El usuario realiza una operación sobre la base de datos (una consulta, modifica o añade un dato, etc.)
2. Las aplicaciones las traducen a su forma conceptual utilizando el diccionario de datos, que posee todos los metadatos necesarios.
3. El esquema conceptual es traducido por la SGBD a su forma interna, nuevamente con ayuda del Diccionario de Datos.
4. EL SGBD se comunica con el Sistema Operativo para pedir que acceda al disco (estamos, por lo tanto ya en el nivel físico) y recoja los datos requeridos (siempre con ayuda del Diccionario de Datos).
5. El Sistema Operativo accede al almacenamiento físico correspondiente y devuelve los datos al SGBD.
6. El SGBD transforma los datos internos en datos conceptuales y los entrega a la aplicación.

7. La aplicación muestra los datos habiéndolos traducido a una forma (externa) amigable y apta para ser entregada al usuario que hizo la petición.

4.2. Estructura multicapa

El proceso que realiza un SGBD para acceder a los datos está en realidad formado por varias capas que actúan como interface. El usuario nunca accede a los datos directamente. Estas capas son las que consiguen implementar los niveles de abstracción de la base de datos.



Fue el organismo ANSI (en su modelo ANSI/X3/SPARC) la que introdujo una mejora de su modelo de bases de datos en 1988 a través de un grupo de trabajo llamado **UFTG** (*User Facilities Task Group*, grupo de trabajo para las facilidades de usuario). Este modelo toma como objeto principal al usuario habitual de la base de datos y modela el funcionamiento de la base de datos

en una sucesión de capas cuya finalidad es ocultar y proteger la parte interna de las bases de datos.

Desde esta óptica, para llegar a los datos hay que pasar una serie de capas que desde la parte más externa poco a poco van entrando más en la realidad física de la base de datos.

Este marco sigue teniendo vigencia actualmente e indica que el acceso a los datos no es instantáneo, que los datos están protegidos de los usuarios que pasan (sin saberlo) por varias capas de proceso antes de que sus peticiones a la base de datos sean atendidas.

Se explican las capas en detalle:

Aplicaciones de usuario

Es la capa a la que acceden los usuarios. Proporciona el SGBD a los usuarios un acceso más sencillo a los datos. Son, en definitiva, las páginas web y los programas con las que los usuarios manejan la base de datos. Permite abstraer la realidad de la base de datos a las usuarias y usuarios, mostrando la información de una forma más humana.

Capa de acceso a datos

La capa de acceso a datos es la que permite comunicar a las aplicaciones de usuario con el diccionario de datos. Es un software (un *driver* o controlador, en realidad) que se encarga traducir las peticiones del usuario para que lleguen de forma correcta a la base de datos y ésta pueda responder de forma adecuada.

Diccionario de datos

Se trata de una estructura interna del SGBD que contiene todos los metadatos. Esta estructura es la que permite pasar de un nivel a otro.

Núcleo


El núcleo de la base de datos es la capa encargada de traducir todas las instrucciones requeridas y prepararlas para su correcta interpretación por parte del sistema. Realiza la traducción física de las peticiones.

Sistema operativo

Es una capa externa al software SGBD pero es la única capa que realmente accede a los datos en sí. En realidad los SGBD no acceden directamente al disco, sino que piden al Sistema Operativo que lo haga, ya que es el que maneja el sistema de discos.

4.3. Funcionamiento del SGBD

La siguiente ilustración presenta el funcionamiento típico de un SGBD. En ella se reproduce la comunicación entre un usuario que desea acceder a los datos y el SGBD:



1. Los usuarios utilizan una aplicación para acceder a los datos. Estamos en el nivel externo de la base de datos, por lo que la propia aplicación traduce la petición que hizo el usuario de forma sencilla, a una petición entendible por la capa de acceso a los datos.
2. El proceso cliente es el software de acceso a la base de datos y que está instalado en el lado del cliente. Se encarga simplemente de recoger y enviar la petición (comprobando antes si hay comunicación con el servidor de la base de datos).
3. A través de la red (normalmente) el proceso cliente se comunica con el proceso servidor, que es el software de comunicación instalado en el lado del servidor. Ambos procesos (cliente y servidor) forman la capa de acceso a los datos.
4. Estando ya en el servidor, la petición pasa al software del Sistema Gestor de Bases de Datos (habrá aquí, como se ha visto en el apartado anterior una traducción de datos, desde el nivel externo al nivel interno).


5. El SGBD, comprobando el diccionario de datos, comprueba si la petición es correcta.
6. El SGBD también revisa el diccionario de datos (si la petición es correcta) para saber con exactitud en qué archivos y en qué parte dentro de ellos, se encuentran los datos requeridos.
7. Con la información sobre dónde están los datos, el SGBD hace una petición al Sistema Operativo, que es el que tiene capacidad realmente de acceder a los archivos de datos. Por ello la petición del SGBD se traduce al formato utilizado por el Sistema Operativo. El Sistema Operativo accede a los datos.
8. El Sistema Operativo recibe los datos.
9. Se entregan los datos al Sistema Gestor de Bases de Datos o, si ha habido un error al acceder a los datos, se indica el error ocurrido.
10. El SGBD traduce los datos a una forma más conceptual y se los entrega al proceso servidor.
11. Los datos se entregan al proceso cliente.
12. Los datos llegan a la aplicación.
13. La aplicación de usuario traduce los datos recibidos en información presentada de la forma más conveniente para el usuario.

5. Estructura de una base de datos

Las bases de datos están compuestas (como ya se han comentado), de **datos** y de **metadatos**. Los metadatos son datos (valga la redundancia) que sirven para especificar la estructura de la base de datos; por ejemplo qué tipo de datos se almacenan (si son texto o números o fechas ...), qué nombre se le da a cada dato (nombre, apellidos,...), cómo están agrupados, cómo se relacionan,....

De este modo se producen dos visiones de la base de datos:

- **Estructura lógica o conceptual.** Indica la composición y distribución teórica de la base de datos. La estructura lógica sirve para que las aplicaciones puedan utilizar los elementos de la base de datos sin saber realmente cómo se están almacenando.
- **Estructura física.** Es la estructura de los datos tal cual se almacenan en las unidades de disco. La correspondencia entre la estructura lógica y la física se almacena en la base de datos (en los metadatos).




6. Modelos de datos

Una de las características fundamentales de los sistemas de bases de datos es que proporcionan cierto nivel de abstracción de datos, al ocultar las características sobre el almacenamiento físico que la mayoría de usuarios no necesita conocer. Los modelos de datos son el instrumento principal para ofrecer dicha abstracción.


Un **modelo de datos** es un conjunto de conceptos que sirven para describir la estructura de una base de datos: los datos, las relaciones entre los datos y las restricciones que deben cumplirse sobre los datos.

Los modelos de datos se pueden clasificar dependiendo de los tipos de conceptos que ofrecen para describir la estructura de la base de datos. Los modelos de datos de alto nivel, o **modelos conceptuales**, disponen de conceptos muy cercanos al modo en que la mayoría de los usuarios percibe los datos, mientras que los modelos de datos de bajo nivel, o **modelos físicos**, proporcionan conceptos que describen los detalles de cómo se almacenan los datos en el ordenador. Los conceptos de los modelos físicos están dirigidos al personal informático, no a los usuarios finales. Entre estos dos extremos se encuentran los **modelos lógicos**, cuyos conceptos pueden ser entendidos por los usuarios finales, aunque no están demasiado alejados de la forma en que los datos se organizan físicamente. Los modelos lógicos ocultan algunos detalles de cómo se almacenan los datos, pero pueden implementarse de manera directa en un ordenador.



- Los modelos conceptuales utilizan conceptos como entidades, atributos y relaciones. Una **entidad** representa un objeto o concepto del mundo real como, por ejemplo, un jugador de un club deportivo. Un **atributo** representa alguna propiedad de interés de una entidad como, por ejemplo, el nombre o el salario del empleado. Una **relación** describe una interacción entre dos o más entidades, por ejemplo, la relación "jugar en" entre un jugador y su club.


Un ejemplo de representación del modelo conceptual sería el siguiente, usando el Modelo Entidad Relación, aunque existen otros modelos como UML o Modelo Entidad-Relación Extendido:




- Cada SGBD soporta un modelo lógico, siendo los más comunes el **relacional**, el **de red** y el **jerárquico**. Estos modelos representan los datos valiéndose de estructuras de registros, por lo que también se denominan *modelos orientados a registros*. Hay una nueva familia de modelos lógicos, son los **modelos orientados a objetos**, que están más próximos a los modelos conceptuales. Será el modelo relacional el que será caso de estudio durante este curso.

Las siguientes figuras muestran tres modelos lógicos del mismo modelo conceptual.


Modelo relacional



Modelo en red



Modelo jerárquico



- Los modelos físicos o internos describen cómo se almacenan los datos en el ordenador: el formato de los registros, la estructura de los ficheros (desordenados, ordenados, etc.) y los métodos de acceso utilizados (índices, etc.).

A la descripción de una base de datos mediante un modelo de datos se le denomina **esquema de la base de datos**. Este esquema se especifica durante el diseño, y no es de esperar que se modifique a menudo. Sin embargo, los datos que se almacenan en la base de datos pueden cambiar con mucha frecuencia: se insertan datos, se actualizan, etc. Los datos que la base de datos contiene en un determinado momento se denominan **estado de la base de datos** u **ocurrencia de la base de datos**.

La distinción entre el esquema y el estado de la base de datos es muy importante. Cuando definimos una nueva base de datos, sólo especificamos su esquema al SGBD. En ese momento, el estado de la base de datos es el "estado vacío", sin datos. Cuando se cargan datos por primera vez, la base de datos pasa al "estado inicial". De ahí en adelante, siempre que se realice una operación de actualización de la base de datos, se tendrá un nuevo estado. El SGBD se encarga, en parte, de garantizar que todos los estados de la base de datos sean estados válidos que satisfagan la estructura y las restricciones especificadas en el esquema. Por lo tanto, es muy importante que el esquema que se especifique al SGBD sea correcto y se debe tener muchísimo cuidado al diseñarlo. El SGBD almacena el esquema en su catálogo o **diccionario de datos** (metadatos) de modo que se pueda consultar siempre que sea necesario.

7. Arquitectura de los sistemas de bases de datos


Hay tres características importantes inherentes a los sistemas de bases de datos:

- ✓ La separación entre los programas de aplicación y los datos
- ✓ El manejo de múltiples vistas por parte de los usuarios
- ✓ El uso de un catálogo para almacenar el esquema de la base de datos

En 1975, el comité **ANSI-SPARC** (American National Standard Institute - Standards Planning and Requirements Committee) propuso una arquitectura de tres niveles para los sistemas de bases de datos, que resulta muy útil a la hora de conseguir estas tres características.

El objetivo de la arquitectura de tres niveles es el de separar los programas de aplicación de la base de datos física. En esta arquitectura, el esquema de una base de datos se define en tres niveles de abstracción distintos:

- En el **nivel interno** se describe la estructura física de la base de datos mediante un *esquema interno*. Este esquema se especifica mediante un modelo físico y describe todos los detalles para el almacenamiento de la base de datos, así como los métodos de acceso.
- En el **nivel conceptual** se describe la estructura de toda la base de datos para una comunidad de usuarios (todos los de una empresa u organización), mediante un *esquema conceptual*. Este esquema oculta los detalles de las estructuras de almacenamiento y se concentra en describir entidades, atributos, relaciones, operaciones de los usuarios y restricciones. En este nivel se puede utilizar un modelo conceptual o un modelo lógico para especificar el esquema.
- En el **nivel externo** se describen varios *esquemas externos* o *vistas de usuario*. Cada esquema externo describe la parte de la base de datos que interesa a un grupo de usuarios determinado y oculta a ese grupo el resto de la base de datos. En este nivel se puede utilizar un modelo conceptual o un modelo lógico para especificar los esquemas.



La arquitectura de tres niveles es útil para explicar el concepto de ***independencia de datos*** que podemos definir como la capacidad para modificar el esquema en un nivel del sistema sin tener que modificar el esquema del nivel inmediato superior. Se pueden definir dos tipos de independencia de datos:

- La ***independencia lógica*** es la capacidad de modificar el esquema conceptual sin tener que alterar los esquemas externos ni los programas de aplicación. Se puede modificar el esquema conceptual para ampliar la base de datos o para reducirla. Si, por ejemplo, se reduce la base de datos eliminando una entidad, los esquemas externos que no se refieran a ella no deberán verse afectados.

- La **independencia física** es la capacidad de modificar el esquema interno sin tener que alterar el esquema conceptual (o los externos). Por ejemplo, puede ser necesario reorganizar ciertos ficheros físicos con el fin de mejorar el rendimiento de las operaciones de consulta o de actualización de datos. Dado que la independencia física se refiere sólo a la separación entre las aplicaciones y las estructuras físicas de almacenamiento, es más fácil de conseguir que la independencia lógica.

8. Estructuras operacionales


Actualmente casi todos los sistemas gestores de base de datos poseen también la idea operacional en la que se entiende que la base de datos se almacena en un servidor y hay una serie de clientes que pueden acceder a los datos del mismo. Las posibilidades son:

SGBD monocapa

Se trata de Sistemas Gestores instalados en una máquina desde la que se conectan los propios usuarios y administradores. Es decir todo el sistema está en una sola máquina.

La ventaja es la seguridad y la clara desventaja la baja disponibilidad e incomodidad de trabajo.


Es un modelo que sólo se utiliza con bases de datos pequeñas y poca cantidad de conexiones. El software **Access** de **Microsoft** es considerada un sistema gestor monocapa (aunque tiene algunas posibilidades para utilizar en dos capas).



SGBD de dos capas

Usa un modelo de funcionamiento tipo **cliente/servidor**. La base de datos y el sistema gestor se alojan en un servidor, mientras que los clientes acceden desde máquinas distintas a través de la red (sea local o global).

Los usuarios requieren disponer de un software de acceso denominado **cliente de base de datos**. En el servidor hay procesos encargados de atender a estas peticiones.



En los sistemas bicapas hay dos posibilidades:

- **Arquitectura cliente/servidor único.** Un solo servidor gestiona la base de datos, todos los clientes se conectan a él para realizar las peticiones a la base de datos.
- **Arquitectura cliente/multiservidor.** La base de datos se distribuye entre varios servidores. El cliente no sabe realmente a qué servidor se conecta; el software de control de comunicaciones se encargará de dirigir al usuario al servidor adecuado. De forma lógica, es como si se tratara de un solo servidor aunque físicamente sean muchos (el cliente no percibe que haya más de un servidor).

SGBD de tres o más capas

En este caso entre el cliente y el servidor hay al menos una capa intermedia (puede haber varias). Esa capa (o capas) se encarga de recoger las peticiones de los clientes y luego de comunicarse con el servidor (o servidores) de bases de datos para recibir la respuesta y enviarla al cliente.



El caso típico es que la capa intermedia sea un servidor web, que recibe las peticiones a través de aplicaciones web; de este modo para conectarse a la base de datos, el usuario solo requiere un navegador web, que es un software muy habitual en cualquier máquina y por lo tanto no requiere una instalación de software adicional en la máquina cliente.

Este modelo es el que más se está potenciando en la actualidad por motivos de seguridad y ocultación de la base de datos.

El servidor intermedio, en muchos casos, realmente es el que aloja la interfaz de manejo de los usuarios de la base de datos. En términos del modelo ANSI, es el que almacena y sirve los esquemas externos de la base de datos.