

Tema 1

SISTEMAS DE ALMACENAMIENTO DE LA INFORMACIÓN Parte 2

**IES Francisco Romero Vargas
Departamento de Informática**

1. Sistemas Gestores de Bases de Datos


Un sistema gestor de bases de datos (SGBD) es una aplicación que permite a los usuarios definir, crear y mantener una base de datos, y proporciona acceso controlado a la misma.

En general, un SGBD proporciona los siguientes servicios:

- Permite la definición de la base de datos mediante el *lenguaje de definición de datos (DDL – Data Description Language)*. Este lenguaje permite especificar la estructura y el tipo de los datos, así como las restricciones sobre los datos. Todo esto se almacenará en la base de datos.
- Permite la inserción, actualización, eliminación y consulta de datos mediante el *lenguaje de manejo de datos (DML – Data Manipulation Language)*.
- Proporciona un acceso controlado a la base de datos mediante:
 - un **sistema de seguridad**, de modo que los usuarios no autorizados no puedan acceder a la base de datos, mediante el lenguaje de control de datos (**DCL – Data Control Language**);
 - un **sistema de integridad** que mantiene la integridad y la consistencia de los datos;
 - un **sistema de control de concurrencia** que permite el acceso compartido a la base de datos;
 - un **diccionario de datos** o catálogo accesible por el usuario que contiene la descripción de los datos de la base de datos.

A diferencia de los sistemas de ficheros, el SGBD gestiona la estructura física de los datos y su almacenamiento. Con esta funcionalidad, el SGBD se convierte en una herramienta de gran utilidad. Sin embargo, desde el punto de vista del usuario, se podría discutir que los SGBD han hecho las cosas más complicadas, ya que ahora los usuarios ven más datos de los que realmente quieren o necesitan, puesto que ven la base de datos completa. Conscientes de este problema, los SGBD proporcionan un mecanismo de **vistas**, que son reflejo de las tablas y permite que cada usuario tenga su propia vista o visión de la base de datos.

Anatomy of a View



Las **vistas**, además de reducir la complejidad permitiendo que cada usuario vea sólo la parte de la base de datos que necesita, tienen otras ventajas:

- Las vistas proporcionan un nivel de seguridad, ya que permiten excluir datos para que ciertos usuarios no los vean.
- Las vistas proporcionan un mecanismo para que los usuarios vean los datos en el formato que deseen.
- Una vista representa una imagen consistente y permanente de la base de datos, incluso si la base de datos cambia su estructura.

Hay dos tipos de lenguajes de manejo de datos que se distinguen por el modo de acceder a los datos:

- Los lenguajes procedurales manipulan la base de datos registro a registro, mientras que los no procedurales operan sobre conjuntos de

registros. En los lenguajes procedurales se especifica qué operaciones se deben realizar para obtener los datos

- Los lenguajes no procedurales especifican qué datos deben obtenerse sin tener que decir cómo hacerlo. El lenguaje no procedural más utilizado es el **SQL (Structured Query Language)** que, de hecho, es un estándar y es el lenguaje de los SGBD relacionales. SQL asume el papel, por tanto, de DDL, DML y DCL.

2. Funciones de los SGBD

Los servicios o funciones que debe ofrecer todo SGBD son.

1. Un SGBD debe proporcionar a los usuarios la capacidad de almacenar datos en la base de datos, acceder a ellos y actualizarlos. Esta es la función fundamental de un SGBD y por supuesto, el SGBD debe ocultar al usuario la estructura física interna (la organización de los ficheros y las estructuras de almacenamiento).

2. Un SGBD debe proporcionar un catálogo en el que se almacenen las descripciones de los datos y que sea accesible por los usuarios. Este catálogo es lo que se denomina **diccionario de datos** y contiene información que describe los datos de la base de datos (metadatos). Normalmente, un diccionario de datos almacena:

- Nombre, tipo y tamaño de los datos.
- Nombre de las relaciones entre los datos.
- Restricciones de integridad sobre los datos.
- Nombre de los usuarios autorizados a acceder a la base de datos.
- Esquemas externo, conceptual e interno y correspondencia entre los esquemas.
- Estadísticas de utilización, tales como la frecuencia de las transacciones y el número de accesos realizados a los objetos de la base de datos.

Algunos de los beneficios que reporta el diccionario de datos son los siguientes:

- La información sobre los datos se puede almacenar de un modo centralizado. Esto ayuda a mantener el control sobre los datos, como un recurso que son.
- El significado de los datos se puede definir, lo que ayudará a los usuarios a entender el propósito de los mismos.
- La comunicación se simplifica ya que se almacena el significado

exacto. El diccionario de datos también puede identificar al usuario o usuarios que poseen los datos o que los acceden.

- Las redundancias y las inconsistencias se pueden identificar más fácilmente ya que los datos están centralizados.
- Se puede tener un historial de los cambios realizados sobre la base de datos.
- El impacto que puede producir un cambio se puede determinar antes de que sea implementado, ya que el diccionario de datos mantiene información sobre cada tipo de dato, todas sus relaciones y todos sus usuarios.
- Se puede hacer respetar la seguridad.
- Se puede garantizar la integridad.
- Se puede proporcionar información para auditorías.

3. Un SGBD debe proporcionar un mecanismo que garantice que todas las actualizaciones correspondientes a una determinada transacción se realicen, o que no se realice ninguna. Una **transacción** es un conjunto de acciones que cambian el contenido de la base de datos. Una transacción en el sistema informático de la empresa inmobiliaria sería dar de alta a un empleado o eliminar un inmueble. Una transacción un poco más complicada sería eliminar un empleado y reasignar sus inmuebles a otro empleado. En este caso hay que realizar varios cambios sobre la base de datos. Si la transacción falla durante su realización, por ejemplo porque falla el hardware, la base de datos quedará en un estado inconsistente.

Algunos de los cambios se habrán hecho y otros no, por lo tanto, los cambios realizados deberán ser deshechos para devolver la base de datos a un estado consistente.

4. Un SGBD debe proporcionar un mecanismo que asegure que la base de datos se actualice correctamente cuando varios usuarios la están actualizando concurrentemente. Uno de los principales objetivos de los SGBD es el permitir que varios usuarios tengan acceso concurrente a los datos que comparten. El acceso concurrente es relativamente fácil de gestionar si todos los usuarios se dedican a leer datos, ya que no pueden interferir unos con otros. Sin embargo, cuando dos o más usuarios están accediendo a la base de datos y al menos uno de ellos está actualizando datos, pueden interferir de modo que se produzcan inconsistencias en la base de datos. El SGBD se debe encargar de que estas interferencias no se produzcan en el acceso simultáneo.

5. Un SGBD debe proporcionar un mecanismo capaz de recuperar la base de datos en caso de que ocurra algún suceso que la dañe. Como se ha comentado antes, cuando el sistema falla en medio de una transacción, la base de datos se debe devolver a un estado consistente. Este fallo puede ser a causa de un fallo en algún dispositivo hardware o un error del

software, que hagan que el SGBD aborte, o puede ser a causa de que el usuario detecte un error durante la transacción y la aborte antes de que finalice. En todos estos casos, el SGBD debe proporcionar un mecanismo capaz de recuperar la base de datos llevándola a un estado consistente.

6. Un SGBD debe proporcionar un mecanismo que garantice que sólo los usuarios autorizados pueden acceder a la base de datos. La protección debe ser contra accesos no autorizados, tanto intencionados como accidentales.

7. Un SGBD debe ser capaz de integrarse con algún software de comunicación. Muchos usuarios acceden a la base de datos desde terminales. En ocasiones estos terminales se encuentran conectados directamente a la máquina sobre la que funciona el SGBD. En otras ocasiones los terminales están en lugares remotos, por lo que la comunicación con la máquina que alberga al SGBD se debe hacer a través de una red. En cualquiera de los dos casos, el SGBD recibe peticiones en forma de mensajes y responde de modo similar. Todas estas transmisiones de mensajes las maneja el gestor de comunicaciones de datos.

8. Un SGBD debe proporcionar los medios necesarios para garantizar que tanto los datos de la base de datos, como los cambios que se realizan sobre estos datos, sigan ciertas reglas. La integridad de la base de datos requiere la validez y consistencia de los datos almacenados. Se puede considerar como otro modo de proteger la base de datos, pero además de tener que ver con la seguridad, tiene otras implicaciones. La integridad se ocupa de la calidad de los datos. Normalmente se expresa mediante **restricciones**, que son una serie de reglas que la base de datos no puede violar. Por ejemplo, se puede establecer la restricción de que cada empleado no puede tener asignados más de diez inmuebles. En este caso sería deseable que el SGBD controlara que no se sobrepase este límite cada vez que se asigne un inmueble a un empleado.

9. Un SGBD debe permitir que se mantenga la independencia entre los programas y la estructura de la base de datos. La independencia de datos se alcanza mediante las vistas o subesquemas. La independencia de datos física es más fácil de alcanzar, de hecho hay varios tipos de cambios que se pueden realizar sobre la estructura física de la base de datos sin afectar a las vistas. Sin embargo, lograr una completa independencia de datos lógica es más difícil. Añadir una nueva entidad, un atributo o una relación puede ser sencillo, pero no es tan sencillo eliminarlos.

10. Un SGBD debe proporcionar una serie de herramientas que permitan administrar la base de datos de modo efectivo. Algunas herramientas

trabajan a nivel externo, por lo que habrán sido producidas por el administrador de la base de datos. Las herramientas que trabajan a nivel interno deben ser proporcionadas por el distribuidor del SGBD. Algunas de ellas son:

- Herramientas para importar y exportar datos.
- Herramientas para monitorizar el uso y el funcionamiento de la base de datos.
- Programas de análisis estadístico para examinar las prestaciones o las estadísticas de utilización.
- Herramientas para reorganización de índices.
- Herramientas para aprovechar el espacio dejado en el almacenamiento físico por los registros borrados y que consoliden el espacio liberado para reutilizarlo cuando sea necesario.

3. Ventajas

Los sistemas de bases de datos presentan numerosas ventajas como:

- Menor redundancia de datos.
- Más información sobre los datos.
- Mayor control sobre la consistencia de los datos.
- Compartición de datos (conurrencia).
- Mejora en la integridad de los datos.
- Mejora en la seguridad
- Mejora en la accesibilidad a los datos sin necesidad de ningún programa (SQL).
- Mejora en los servicios de copias de seguridad.

4. Inconvenientes

- Gran cantidad de espacio de disco y de memoria RAM para trabajar eficientemente.
- Coste económico elevado, tanto por el gestor como por el equipamiento adicional.
- Coste de la conversión, tanto de migración de datos como de enseñanza a la plantilla de su uso.
- Vulnerable a los fallos por el hecho de que todo esté centralizado.

5. Lenguajes de los SGBD

Los SGBD deben ofrecer lenguajes e interfaces apropiadas para cada tipo de usuario: administradores de la base de datos, diseñadores, programadores de aplicaciones y usuarios finales.

Lenguaje de definición de datos (DDL)

Una vez finalizado el diseño de una base de datos y escogido un SGBD para su implementación, el primer paso consiste en especificar el esquema conceptual y el esquema interno de la base de datos, y la correspondencia entre ambos. En muchos SGBD, para definir ambos esquemas, se utiliza el *lenguaje de definición de datos* (DDL). El SGBD posee un compilador de DDL cuya función consiste en procesar las sentencias del lenguaje para identificar las descripciones de los distintos elementos de los esquemas y almacenar la descripción del esquema en el catálogo o diccionario de datos (metadatos).

El DDL modifica el ESQUEMA de la BD. Son instrucciones DDL: CREATE, ALTER o DROP.

Lenguaje de manejo de datos (DML)

Una vez creados los esquemas de la base de datos, los usuarios necesitan un lenguaje que les permita manipular los datos de la base de datos: realizar consultas, inserciones, eliminaciones y modificaciones. Este lenguaje es el que se denomina *lenguaje de manejo de datos* (DML).

Hay dos tipos de DML: los procedurales y los no procedurales. Con un DML *procedural* el usuario (normalmente será un programador) especifica qué datos se necesitan y cómo hay que obtenerlos. Esto quiere decir que el usuario debe especificar todas las operaciones de acceso a datos llamando a los procedimientos necesarios para obtener la información requerida. Estos lenguajes acceden a un registro, lo procesan y basándose en los resultados obtenidos, acceden a otro registro, que también deben procesar. Así se va accediendo a registros y se van procesando hasta que se obtienen los datos deseados. Las sentencias de un DML procedural deben estar embebidas en un lenguaje de alto nivel, ya que se necesitan sus estructuras (bucles, condicionales, etc.) para obtener y procesar cada registro individual. A este lenguaje se le denomina *lenguaje anfitrión*. Las bases de datos jerárquicas y de red utilizan DML procedurales.

Un DML *no procedural* se puede utilizar de manera independiente para especificar operaciones complejas sobre la base de datos de forma concisa. Los DML no procedurales permiten especificar los datos a obtener en una consulta o

los datos que se deben actualizar, mediante una sola y sencilla sentencia. El usuario o programador especifica qué datos quiere obtener sin decir cómo se debe acceder a ellos. El SGBD traduce las sentencias del DML en uno o varios procedimientos que manipulan los conjuntos de registros necesarios. A los DML no procedurales también se les denomina *declarativos*. Las bases de datos relacionales utilizan DML no procedurales, como SQL (Structured Query Language) o QBE (Query-By-Example). Los lenguajes no procedurales son más fáciles de aprender y de usar que los procedurales, y el usuario debe realizar menos trabajo, siendo el SGBD quien hace la mayor parte.

El DML modifica el ESTADO de la BD. Son instrucciones DML: INSERT, UPDATE, DELETE o SELECT.

Lenguaje de control de datos (DCL)

Los lenguajes de control de datos contienen elementos útiles para trabajar en entornos multiusuario en los que son importantes la protección de datos, la seguridad de las tablas y el establecimiento de restricciones en el acceso, así como elementos para coordinar la compartición de datos por parte de usuarios concurrentes, asegurando que no interfieren unos con otros.

El DCL controla el acceso a los datos de la BD. Son instrucciones DCL: GRANT o REVOKE.

6. Clasificación de los sistemas gestores de bases de datos

Según el modelo lógico utilizado

El criterio principal que se utiliza para clasificar los SGBD es el modelo lógico en que se basan. Los modelos lógicos empleados con mayor frecuencia en los SGBD comerciales actuales son el relacional y el objeto-relacional. El de red, el jerárquico están obsoletos.

El **modelo relacional** se basa en el concepto matemático denominado "relación", que gráficamente se puede representar como una tabla. En el modelo relacional, los datos y las relaciones existentes entre los datos se representan mediante estas relaciones matemáticas, cada una con un nombre que es único y con un conjunto de columnas. Véase el anexo "Las 12 reglas de Codd".

En el modelo relacional la base de datos es percibida por el usuario como un conjunto de tablas. Esta percepción es sólo a nivel lógico (en los niveles externo

y conceptual de la arquitectura de tres niveles), ya que a nivel físico puede estar implementada mediante distintas estructuras de almacenamiento. **Oracle**, **MySQL** y **PostgreSQL**, por ejemplo, son SGBD relacionales muy populares. Es el modelo que estudiaremos durante este curso (**MariaDB**).

En el **modelo de red** los datos se representan como colecciones de registros y las relaciones entre los datos se representan mediante conjuntos, que son punteros en la implementación física. Los registros se organizan como un grafo: los registros son los nodos y los arcos son los conjuntos. El SGBD de red más popular es el sistema IDMS. Su manejo es complejo y poco intuitivo. Predominó hasta los años 80.

El **modelo jerárquico** es un tipo de modelo de red con algunas restricciones. De nuevo los datos se representan como colecciones de registros y las relaciones entre los datos se representan mediante conjuntos. Sin embargo, en el modelo jerárquico cada nodo puede tener un solo padre. Una base de datos jerárquica puede representarse mediante un árbol: los registros son los nodos, también denominados segmentos, y los arcos son los conjuntos. El SGBD jerárquico más importante es el sistema IMS. Totalmente obsoleto por no poder reflejar relaciones complejas.

El **modelo orientado a objetos** define una base de datos en términos de objetos, que permite unir datos (atributos) y operaciones sobre los datos (métodos). Los objetos con la misma estructura y comportamiento pertenecen a una clase. Para definir el modelo conceptual se usa normalmente UML (Unified Modeling Language – Lenguaje unificado de modelado). Son muy fáciles de asociar a lenguajes modernos como Java, C# o C++, aunque no han tenido mucho éxito.

Algunos SGBD relacionales existentes en el mercado han estado extendiendo sus modelos para incorporar conceptos orientados a objetos. A estos SGBD se les conoce como sistemas **objeto-relacionales**, que intentan unir lo mejor de los dos modelos. Se basan en la normativa ISO SQL 2000. Casi todas las bases de datos relacionales actuales utilizan, realmente, este último modelo, aunque suelen denominarse únicamente relacionales.

Actualmente existen en el mercado las denominadas bases de datos **NoSQL**, como, por ejemplo, **MongoDB**. En estos gestores las bases de datos no tienen un identificador que sirva de relación entre unas tablas y otras. La información que contienen está organizada mediante documentos (o pares clave-valor, o columna ancha, ...) y son muy útiles cuando no se tiene un esquema exacto de lo que se va a almacenar. Se caracterizan por permitir una mayor escalabilidad horizontal (es decir, pueden añadirse fácilmente nuevos nodos) y están optimizadas para grandes cantidades de datos.

Según el número de usuarios a los que da servicio

Un segundo criterio para clasificar los SGBD es el número de usuarios a los que da servicio el sistema. Los sistemas **monousuario** sólo atienden a un usuario a la vez, y su principal uso se da en los ordenadores personales. Los sistemas **multiusuario**, entre los que se encuentran la mayor parte de los SGBD, atienden a varios usuarios al mismo tiempo.

Según la distribución física de la base de datos

Un tercer criterio es el número de sitios en los que está distribuida la base de datos. Casi todos los SGBD son **centralizados**: sus datos se almacenan en un solo computador. Los SGBD centralizados pueden atender a varios usuarios, pero el SGBD y la base de datos en sí residen por completo en una sola máquina. En los SGBD **distribuidos** la base de datos real y el propio software del SGBD pueden estar distribuidos en varios sitios conectados por una red. Empleando una arquitectura cliente-servidor.

Según el coste

Un cuarto criterio es el coste del SGBD. La mayor parte de los paquetes de SGBD cuestan entre 10.000 y 100.000 euros. Los sistemas monousuario más económicos para microcomputadores cuestan entre 100 y 3.000 euros. En el otro extremo, los paquetes más completos cuestan más de 100.000 euros.

Estamos hablando de los **sistemas propietarios**. Este mercado se reparte, principalmente, entre tres empresas: IBM, con **DB2**, **Oracle**, con la veterana y prestigiosa serie **xI** y **Microsoft SQL Server**.

Pero existen iniciativas basadas en **sistemas de código abierto** (OSS). Entre los desarrolladores más conocidos figuran Borland, con **Firebird**, y **PostgreSQL**. Sin embargo, el líder indiscutido en el mercado de bases de datos de código abierto es **MySQL**, propiedad de la empresa sueca MySQL AB. Prueba de ello son los cuatro millones de instalaciones y las 30.000 descargas online diarias. Actualmente pertenece a Oracle, pero los fundadores de MySQL ofrecen una adaptación gratuita denominada **MariaDB**.

Dentro de los proyectos de dominio público, uno de los gestores de bases de datos más utilizados por los desarrolladores es **SQLite**, que es un sistema de gestión de bases de datos relacional compatible con ACID, contenida en una relativamente pequeña biblioteca escrita en C. A diferencia de los sistemas de gestión de bases de datos cliente-servidor, el motor de SQLite no es un proceso independiente con el que el programa principal se comunica. En lugar de eso, la biblioteca SQLite se enlaza con el programa pasando a ser parte integral del

mismo. El programa utiliza la funcionalidad de SQLite a través de llamadas simples a subrutinas y funciones. Esto reduce la latencia en el acceso a la base de datos, debido a que las llamadas a funciones son más eficientes que la comunicación entre procesos. El conjunto de la base de datos (definiciones, tablas, índices, y los propios datos), son guardados como un solo fichero estándar en la máquina host. Este diseño simple se logra bloqueando todo el fichero de base de datos al principio de cada transacción. En su versión 3, **SQLite** permite bases de datos de hasta 2 Terabytes de tamaño, y también permite la inclusión de campos tipo BLOB.

Actualmente, la tendencia de almacenar datos en la nube se está incrementando. Por ejemplo, **Amazon Relational Database Service** permite configurar, utilizar y escalar una base de datos relacional en la nube. Amazon RDS está disponible para varios tipos de instancias de base de datos (optimizadas para memoria, rendimiento u operaciones de E/S) y le proporciona seis motores de bases de datos conocidos entre los que elegir, incluidos Aurora, PostgreSQL, MySQL, MariaDB, Oracle Database y SQL Server. Se puede usar AWS Database Migration Service para migrar o replicar las bases de datos existentes en Amazon RDS con facilidad.

Las ventajas de usar una base de datos relacional en la nube es que es un formato familiar y popular, especialmente para el análisis de datos, al mismo tiempo que acelera el negocio al aprovechar la nube para reducir los costos y aumentar la velocidad y la escalabilidad. Algunos de estos gestores en la nube son **Microsoft Azure**, **Snowflake Computing**, **Oracle Database Cloud Service**, **Google Cloud**, etc.

Según el propósito

Por último, los SGBD pueden ser de **propósito general** o de **propósito específico**. Cuando el rendimiento es fundamental, se puede diseñar y construir un SGBD de propósito especial para una aplicación específica, y este sistema no sirve para otras aplicaciones. Muchos sistemas de reservas de líneas aéreas son SGBD de propósito especial y pertenecen a la categoría de *sistemas de procesamiento de transacciones en línea* (OLTP), que deben atender un gran número de transacciones concurrentes sin imponer excesivos retrasos.